

Определение токсичности химических веществ

Посмотрим на исходный датасет

Мы собрали данные с разных источников по токсичности химических веществ. Определили оптимальной метрикой токсичности параметр LD50. Для каждого SMILES (уникальный идентификатор вещества) рассчитали дескрипторы. Сводный датасет, с которым работали на данном этапе представляем

Загрузка CSV файла

Выберите CSV файл



Drag and drop file here

Limit 200MB per file • CSV

Browse files



dataset_for_show.csv 167.8MB



Введите количество строк для отображения:

5



Показать загруженный датасет

Предобработка

Избавляемся от дубликатов, оставляем для предсказания только таргет LD50

☒ Сделаем предобработку датасета

Датасет успешно предобработан

Мы хотим убедиться, что у нас нет признаков, которые были бы статичные во всем датасете, чтобы минимизировать риск переобучения на них, поэтому сразу удаляем их

Удаляем столбцы, где 99.6% значений — это одно уникальное значение

Введите порог для удаления столбцов (у нас используется 99.6%):

1,00

-

+

Удалить признаки с постоянными значениями

Данные очищены. Осталось столбцов: 1384


	Exp. Animal	Method of administration	LD50	MaxAbsEStateIndex	MaxEStateIndex	MinAbsEStateIndex
0	mouse	intraperitoneal	300	9.349	9.349	
1	mouse	intraperitoneal	200	9.5642	9.5642	
2	mouse	intraperitoneal	200	9.9107	9.9107	
3	mouse	intraperitoneal	178	11.761	11.761	
4	mouse	intraperitoneal	140	5.9715	5.9715	
5	rat	oral	347	5.9715	5.9715	
6	mouse	intraperitoneal	143	13.2644	13.2644	
7	mouse	oral	630	13.2644	13.2644	
8	mouse	intraperitoneal	273	5.9774	5.9774	
9	mouse	oral	900	5.9774	5.9774	

Анализ данных LD50


Показать график LD50

Показать график log_LD50

Гистограмма LD50



Гистограмма LD50



Обучение модели на всех признаках

Обучить модель

Обучение завершено!

R^2 на трейне: -0.0615

R^2 на тесте: -20.9127

MAPE на трейне: 8.8340

MAPE на тесте: 12.3541

Коэффициенты модели

	weights
MaxEStateIndex	2,575,527,224,631.9546
NumSaturatedCarbocycles	1,017,212,054,958.8568
NumSaturatedHeterocycles	871,896,047,105.8429
fr_COO	202,368,387,682.5945
fr_Nhpyrrole	97,677,533,202.7164
NumAliphaticCarbocycles	80,109,427,419.7631
NumAliphaticHeterocycles	74,387,325,458.9873
RingCount	59,481,363,377.9676
GROUPIVA,VA,VIAPERIODS45447(Ge...)	43,649,561,946.3847
A\$A!O	31,050,188,073.6715

Исходя из различий метрик на трейне и тесте, а также полученным весам модели, предполагаем, что модель переобучилась. Необходимо провести отбор признаков для повышения точности модели.

Попробуем применить различные методы для уменьшения количества переменных в наборе данных

Отбор признаков

РСА и линейная регрессия

РСА и линейная регрессия

РСА проведено. Линейная модель обучилась

Размерность после РСА:

X_train_pca: (27219, 760), X_test_pca: (9073, 760)

R^2 на трейне: 0.09241430056487554


R^2 на тесте: 0.0920

MAPE на трейне: 16.0266

MAPE на тесте: 21.1806

MAPE на кросс-валидации: 330.69 ± 337.61

Предсказанные и фактические значения



	weights
PC291	0.8378
PC271	0.7019
PC39	0.6084
PC351	0.5364
PC646	0.5024
PC346	0.4883
PC294	0.4696
PC283	0.4598
PC299	0.4545
PC592	0.4194

Видим, что коэффиценты модели уменьшились. Наш датасет с признаками представляет собой разреженную матрицу, можно попробовать адаптировать PCA как раз для модели разреженных данных.

☐ Сохранить модель

SVD

SVD

Размер X_train до SVD: (27219, 1387)

Размер X_train после SVD: (27219, 600)

Размер X_test после SVD: (9073, 600)

R² на трейне: 0.0926

R² на тесте: 0.0886


MAPE на трейне: 22.4152

MAPE на тесте: 29.1442

MAPE на кросс-валидации: 1.94 ± 0.29

Доля объясненной дисперсии: 91.69%

Предсказанные и фактические значения



☐ Сохранить модель SVD

SelectKBest

SelectKBest

R² на трейне: -0.0585


R² на тесте: 0.0206


MAPE на трейне: 20.2103

MAPE на тесте: 26.8282

MAPE на кросс-валидации:: 2.94 ± 0.71

Предсказанные и фактические значения





☐ Сохранить модель SKB

Подбор гиперпараметров

Grid Search для Lasso Регрессии

Здесь мы можем выбрать на каком наборе данных будем проводить GS

Выберите вариант X_train:

Без сжатия признакового пространства



Минимальное значение alpha:

0,000100

- +

Максимальное значение alpha:

0,010000

- +

Количество точек для alpha:

10



1

100

Запустить Grid Search

Модель предсказания LD50

Теперь покажем, как наша модель работает. Для этого предварительно запускаем сервер с FastAPI

Обучение модели

Выберите CSV файл



Drag and drop file here

Limit 200MB per file • CSV

Browse files



result_with_features_api.csv 20.9MB



Обучение модели

Предсказание

Введите SMILES:

CCO

Выберите экспериментальное животное:

mouse



Выберите метод введения:

oral



Сделать предсказание

Сохранение модели

Сохранить модель

Введите ID модели для установки

Default_model

Установить модель

Показать список моделей



[

```
▼ 0 : {  
  "id" : "Default_model"  
  "scaler" : "MinMaxScaler"  
  "encoder" : "OHE"  
  "feature_selector" : "PCA"  
}  
▼ 1 : {  
  "id" : "Model2"  
  "scaler" : "MinMaxScaler"  
  "encoder" : "OHE"  
  "feature_selector" : "PCA"  
}  
▼ 2 : {  
  "id" : "pipeline_model"  
  "scaler" : "MinMaxScaler"  
  "encoder" : "OneHotEncoder"  
  "feature_selector" : "PCA"  
}  
]
```