

Проект: Определение токсичности химических веществ

В нашем проекте мы реализовали ML-модель, которая позволяла бы предсказывать метрику токсичности исходя из названия вещества (под названием принимаем однозначный идентификатор вещества - SMILES).

Были собраны данные из различных источников, предобработаны и сведены в один датасет. Идентификатор вещества SMILES мы переводили в дескрипторы (это числовые характеристики, получаемые в результате моделирования физико-химических свойств химических соединений, либо величины, имеющие четкую физико-химическую интерпретацию). На основании дескрипторов, методов введения вещества и животных, над которыми проводили эксперименты, мы обучали нашу модель. В качестве метрики токсичности использовали на данном этапе LD50, ввиду большего количества данных именно по ней.

Далее проводили работы по отбору признаков (логический анализ, применение метод сжатия признакового пространства и т.д.) и подбору оптимальной модели.

Эти результаты (3 чекпоинт) по разработке baseline мы оформили в виде Streamlit-приложения.

Стоит обратить внимание, что ввиду того, что мы представляем на данном этапе обрезанный датасет (ограничение по загрузке файлов в GitHub), результаты незначительно могут отличаться, но основную концепцию передали.

Функционал модели показан в серверной части на основании FastAPI, а также клиентские запросы можно делать через

1. Контейнеризация backend части (FastAPI) проведена в Docker локально и загружена на DockerHub

Сборка контейнера `docker build -t toxpredict .`

- Чтобы открыть контейнер надо загрузить его образ из DockerHub
- Войдите в свою учетную запись docker login
- Для скачивания контейнера обратитесь по команде `docker pull gaydukovadd/toxpredict:latest`
- Далее обращаемся к нему через команду `docker run -p 8000:8000 toxpredict uvicorn fastAPI:app --host 0.0.0.0 --port 8000`
- Запущенный контейнер доступен по ссылке `http://127.0.0.1:8000`

Для загрузки файла на обучение предлагаем брать `code/app/result_with_features_api.csv`

FastAPI 0.1.0 OAS 3.1
/openapi.json

default ^	
POST	/fit Fit Model
POST	/predict_smile Predict Smile
POST	/save Save
POST	/set Set
GET	/list_models List Models

2. Frontend

Чтобы запустить приложение Streamlit необходимо выполнить команду `streamlit run streamlitapp.py` - переход на страничку будет автоматическим

Весь ход работы в этом чекпоинте описан в данном приложении (однако датасет урезан ввиду долгих внутренних процессов предобработки и обучения модели, используем "`\dataset_for_show.csv`").

Чтобы получить файл необходимо его скачать по ссылке:

<https://mega.nz/file/Lc4WFZqb>

Ключ шифрования: `lcVcBP1Tp0BjBPZwBi4yWjacy2cEBFunSj5bMwcFPE0`

Для полного датасета:

<https://mega.nz/file/nBZigKZS>

Ключ шифрования: `gjWiFch8EFoC_67K2vBP1HBS9x7UXqo4D07gST0oIow`

Что примерно должны увидеть после запуска приложения:

Определение токсичности химических веществ

Посмотрим на исходный датасет

Мы собрали данные с разных источников по токсичности химических веществ. Определили оптимальной метрикой токсичности параметр LD50. Для каждого SMILES (уникальный идентификатор вещества) рассчитали дескрипторы. Сводный датасет, с которым работали на данном этапе представляем

Загрузка CSV файла

Выберите CSV файл

Drag and drop file here
Limit 200MB per file • CSV

Browse files

dataset_for_show.csv 167.8MB

Введите количество строк для отображения:

5

Показать загруженный датасет

Предобработка

Избавляемся от дубликатов, оставляем для предсказания только таргет LD50

☒ Сделаем предобработку датасета

Датасет успешно предобработан ✓

Также там реализован клиентский запрос через FastAPI (предварительно необходимо запустить сервер по инструкции выше).