



Команда 86

Куратор команды:
Бугров Артём

Состав команды:
Гайдукова Дарья
Токарев Владислав
Ядыкин Даниил

Проектная работа на тему:

Прогнозирование токсичности химических веществ



Постановка задачи и цели на год

Цель работы: разработка модели машинного обучения для прогнозирования токсичности химических соединений.

Статус:

-  Сбор данных о токсичности;
-  Генерация физико-химических дескрипторов (MACCS, MorganFingerprints, 2D-дескрипторы);
-  EDA;
-  Создание бейзлайн моделей регрессии;
-  Разработка MVP сервиса для работы с моделями;
-  Улучшение бейзлайна;
-  Развитие сервиса для работы с моделями;
-  Эксперименты с DL.






Источники данных

3

30 источников -> 5 лучших



Подходы:

1. Подключение к API БД;
2. Ручной сбор путём скачивания файлов xls/csv.

Структура датасета после сбора данных

Поле	Описание
Smiles	Смайлс химического вещества
the experimental animal	подопытное животное
the input method	метод введения вещества
metric_1	найденная метрика №1
metric_2	найденная метрика №2
...	...
metric_N	найденная метрика №N

Исходные данные сохранены в [объектном хранилище](#).

*Smiles – уникальный идентификатор химического соединения в большинстве баз данных



Генерация признаков и EDA


4

	Source	Smiles	Exp. Animal	Method of administration	LD50	LD50 (a.u.)
0	ChEMBL	Br.Br.Cc1cc(-c2ccc(O)cc2)nnc1NCCN1CCOCC1	mouse	Intraperitoneal	300.00	mg/kg
1	ChEMBL	Br.Br.Cc1cc(-c2cccc(O)c2)nnc1NCCN1CCOCC1	mouse	Intraperitoneal	200.00	mg/kg
2	ChEMBL	Br.Br.Cc1cc(-c2cccc2O)nnc1NCCN1CCOCC1	mouse	Intraperitoneal	200.00	mg/kg
3	ChEMBL	Br.CC(=O)c1ccc(NC(=O)CCN2CCN(c3ccc(Br)cn3)CC2)cc1	admet	Oral	3585.75	mg/kg
4	ChEMBL	Br.CC(C)C(N)C(=O)NNc1nncc(-c2ccc(Cl)cc2)n1.O	mouse	Intraperitoneal	178.00	mg/kg

5 rows × 22 columns Размерность датасета до и после EDA (171314, 22) -> (114757, 1422)

Что было проведено на EDA:

1. Удалены выбросы и пропуски в данных
2. Унифицирован тип животного и способ введения
3. Избавление от метрик без единиц измерения
4. Графики по некоторым признакам (корреляции, тепловые диаграммы и т.д.)
5. Логарифмирование таргета
6. Оптимизация памяти в датасете.




*Дескрипторы– общепринятый в химии способ описания физико-химических свойств молекул



Построение бейзлайна модели

5


Модель	Результат	Доп. параметры
LinearRegression + PCA	MAPE на кросс-валидации: 278.32 ± 184.73	792 важных признака
LinearRegression + L1/L2/ElasticNet	Не дало прироста метрик	-
LinearRegression + TruncatedSVD	MAPE на кросс-валидации: 2.94 ± 0.40	600 важных признаков
LinearRegression + KBest	MAPE на кросс-валидации: 4.20 ± 0.77	-
Ridge (alpha=50) + f-regression	MAPE на тесте 23.95	800 важных признаков





Сервисная часть

6



- ☐ Использовано логирование
- ☐ Применены методы Pydantic, typing



Демонстрация представлена в отдельном файле .pdf



Демонстрация представлена в отдельном файле .pdf



Демонстрация представлена в отдельном файле .pdf



Вклад участников команды

10

Этап проекта	Токарев Владислав	Гайдукова Дарья	Ядыкин Данил
Сбор данных	Осуществлял сбор данных в рамках зоны своей ответственности	Осуществляла сбор данных в рамках зоны своей ответственности	Осуществлял сбор данных в рамках зоны своей ответственности
Генерация признаков + EDA	Генерировал 2D дескрипторы	Генерировала MACCS дескрипторы	Генерировал MorganFingerprints дескрипторы
Бейзлайн модели	Написал несколько моделей	Написала одну модель	Написал одну модель
Сервисная часть	FastAPI	Streamlit Сборка образов по backend и frontend Контейнеризация на DockerHub	FastAPI



Спасибо за внимание!